Bitácora de IA · Centinela del Café · Fase 1

Por: Julio César González R

1. Datos de la entrega

Campo	Detalle
Integrantes	Julio César González Rodríguez (presenta individual)
Proyecto	Centinela del Café: hoja de café robusta enferma (roya o ácaro) sí/no, a partir de rasgos de la foto
Fase	Fase 1 · MLP
Primer identificador de esta fase	E-1
Fecha de entrega	2026-10-31

2. Declaración de uso de IA

Quien firma declara que durante esta fase usó:

Claude (Anthropic) para la corrección y generación del código que me presentaba problemas en colab, así como para buscar una segunda opinión de los resultados obtenidos para buscar un mejor refinamiento.

Quien firma declara también que comprende, verificó y puede defender como propio cada artefacto entregado, y que esta bitácora refleja con honestidad cómo se usó la herramienta.

Integrante	Firma	Fecha
Julio César González R.		2026-10-31

3. Registro de interacciones

E1 Descarga de las fotos de RoCoLe

Campo	Registro
Fecha y hora	2026-10-30 20:22 (aprox.)
Fase · paso	F1 · Paso 1
Celda afectada	Celda 1 (# E-1) y celda 12
Objetivo	Obtener las 1.560 fotos desde el productor primario
Indicación (resumen)	Explorar la API pública de Mendeley para descargar las fotos
Qué devolvió la IA	Listar la carpeta `Photos` y descargar archivo por archivo; ante el corte, probó &offset=1000, &page=2, &limit=2000 y cabeceras Range

Campo	Registro
Datos compartidos	Ninguno
Decisión	Rechazada (se reemplazó por el paquete `RoCoLe-voc.tar.gz`)
Justificación	La API devuelve como máximo 1.000 archivos y no pagina: el listado pierde en silencio 560 fotos (36 %)
Cómo se verificó	Cabecera literal `content-range: items 0-999/1560`; los seis intentos de paginación devolvieron el mismo primer archivo (`C10P10E1.jpg`). Con el VOC: 1.560 imágenes con rasgos
Evidencia de origen	Salida literal de la herramienta en la sesión (sección 4)

E2 · Partición por planta

Campo	Registro
Fecha y hora	2026-10-30 20:24 (aprox.)
Fase · paso	F1 · Paso 1
Celda afectada	Celda 5
Objetivo	Elegir la estrategia de partición
Qué devolvió la IA	Del nombre de archivo (C1P2E2.jpg) dedujo 390 plantas con ≈ 4 hojas cada una; 374 tienen hojas sanas y enfermas. Propuso GroupShuffleSplit por planta
Datos compartidos	Ninguno
Decisión	**Aceptada**
Justificación	Hojas de la misma planta comparten luz y sesión: mezclarlas entre conjuntos inflaría la prueba (fuga por grupo, Cap. 5)
Cómo se verificó	`assert` de la celda 5: ninguna planta aparece en dos conjuntos

E3 · Huella SHA-256 de NASA POWER

Campo	Registro
Fecha y hora	2026-10-30 20:34
Fase · paso	F1 · Paso 0 (anexo B)
Celda afectada	Celda 1
Objetivo	Calcular la huella del archivo de clima

Campo	Registro
Qué devolvió la IA	Primero, la huella de la respuesta completa (`7ddd6f10…`)
Decisión	**Modificada**: huella del bloque `properties.parameter` con claves ordenadas
Justificación	La respuesta incluye times (tiempo de proceso), que cambia en cada consulta: la huella del archivo crudo no es reproducible
Cómo se verificó	Tres consultas idénticas dieron tres huellas distintas (7ddd6f10…, 9e49043c…, 40b0f5fe…; times.data = 0,325 · 0,522 · 0,344 s); la huella del bloque de datos es estable (02da8ae0…)
Evidencia de origen	Salida literal de la herramienta en la sesión

E4 · Error de compatibilidad con pandas

Campo	Registro
Fecha y hora	2026-10-30 20:28 (aprox.)
Fase · paso	F1 · Paso 5
Celda afectada	Celdas 10c y 11
Objetivo	Seleccionar diez hojas por clase y resumir errores por severidad
Qué devolvió la IA	`groupby(...).apply(..., include_groups=True)`
Decisión	Modificada: `pd.concat` por clase y `groupby(...).agg(...)`
Justificación	Esa opción ya no existe en pandas reciente; además el resultado debe correr igual en Colab
Cómo se verificó	Error literal: ValueError: include_groups=True is no longer allowed. Tras el cambio, el cuaderno corre de punta a punta
Evidencia de origen	Traza del error en la prueba del cuaderno

5 · Mes de la clave de alineación

Campo	Registro
Fecha y hora	2026-10-30 20:25 (aprox.)
Fase · paso	F1 · Paso 0 (sección 5)
Celda afectada	Celda 11
Objetivo	Fijar el mes de la clave (región, mes) sin fecha por foto

Campo	Registro
Qué devolvió la IA	`date_captured` es nulo; los identificadores de Labelbox fechan la carga entre el 14 y el 17 de mayo de 2019; propuso abril de 2019
Decisión	Aceptada con salvedad declarada (rasgo constante; mes aproximado)
Justificación	Catálogo: el join del café es agregado y se declara con sus salvedades; no se inventa un pareo por muestra
Cómo se verificó	Archivo COCO de RoCoLe (date_captured: null) y columna Created At del CSV (2019-05-14 a 2019-05-17)

4. Auditoría a la IA

Tipo: real. La IA produjo el fallo durante el proyecto (entrada E-1).

El fallo. Para descargar las fotos, la IA propuso listar la carpeta `Photos` de RoCoLe en la API pública de Mendeley y bajar los archivos uno a uno, suponiendo que el listado traía los 1.560. El código no falla: descarga 1.000 fotos y sigue. Es un error que cambia los datos del proyecto.

Evidencia de origen (salida literal de la herramienta, 2026-10-30):

GET /public-api/datasets/c5yvn32dzg/files?version=2&folder_id=1ca51fea-…
→ 206 · content-range: items 0-999/1560 · 1000 archivos · primero: C10P10E1.jpg
&offset=1000 → 206 · 1000 archivos · primero: C10P10E1.jpg
&page=2 → 206 · 1000 archivos · primero: C10P10E1.jpg
Range: items=1000-1559 → content-range: items 0-999/1560
Corrección y fundamento. Se descarga RoCoLe-voc.tar.gz, un solo archivo con las 1.560 fotos y huella SHA-256 publicada por Mendeley, y se comprueba que el número de imágenes con rasgos coincida con las filas del CSV. Fundamento: la Propuesta aprobada fija el conjunto; el cuaderno debe usar exactamente esas fuentes, completas.

Reproducción (celda 12 del cuaderno): misma semilla (42), misma partición por planta, mismo MLP 16 → 8 y misma regla de umbral (recall ≥ 0,90 en validación). Solo cambia el conjunto de hojas.

Versión	Hojas totales	Hojas en prueba	*Recall* «enferma»	AUC	Exactitud	FN	FP
IA: listado de `Photos` (truncado)	1.000	208	0,848	0,916	0,832	15	20
Corregida: paquete VOC completo	1.560	312	0,891	0,910	0,801	16	46

Veredicto. El listado no corta al azar: devuelve los 1.000 primeros nombres en orden alfabético, así que deja fuera **lotes completos** del cultivo (secciones C6 a C9 y parte de C5). La versión de la IA detecta menos enfermas (*recall* 0,848 frente a 0,891), pero su AUC y su exactitud se ven **mejores**. Ese es el peligro: un error de datos que no parece un error. Con independencia de cuánto cambie el *recall*, la versión de la IA evalúa con un tercio menos de hojas y no usa el conjunto aprobado.